# 多元线性回归 · 理论与案例

> 本文件 = **六层理论** + **完整案例**（2022 MCM C 题风格：金价驱动因素）+ **可运行代码**
> 配套代码：`mlr_demo.py`（同目录，已跑通）
> 出图：`fig_mlr_fit_resid.png`
> 前置：`AHP模型与建议.md`（评价类）已学完，本节进入**预测/解释类**

---

# 第一部分 · 理论（六层）

## 第一层：定位 —— 它解决什么问题

**一句话**：用若干个"因"，去解释/预测一个"果"，并且量化每个因贡献多少。

| 问题 | 回答 |
|---|---|
| 核心问题 | 一个连续变量 y，受哪些因素影响？影响多大？给定 x 能否预测 y？ |
| 输入 | `n × k` 数值表：1 列 y（连续）+ k 列 x（连续/虚拟变量） |
| 输出 | 回归系数 β（每个 x 的边际效应）+ 预测值 ŷ + 区间 + 一堆检验统计量 |
| 数据类型 | 截面或时序都行，**连续型**，**有标签**（监督学习） |
| 方法类别 | **统计模型**（parametric，可解释），也是机器学习里的"线性基线" |

### 它回答两种不同的问题（比赛里最容易混）

| 目的 | 关心什么 | 怎么写进论文 |
|---|---|---|
| **解释**（inference） | 系数大小、正负、显著性（哪个因素最重要） | "实际利率每上升 1 个百分点，金价平均下降 114.7 美元" |
| **预测**（prediction） | 预测误差（RMSE、交叉验证） | "模型对未来 6 个月金价的预测误差为 ±21 美元" |

> 同一套代码，两种目的；但**评价标准完全不同**——解释看 t 检验和 VIF，预测看交叉验证误差。写论文前先想清楚你要哪个。

### 同类竞品

| 竞品 | 关系 | 什么时候换 |
|---|---|---|
| **一元线性回归** | 特例（k=1） | 只有一个因素 |
| **岭回归 / Lasso** | 加了正则化的线性回归 | 共线严重、变量多（Lasso 还能自动选变量） |
| **逻辑回归** | y 是 0/1 时 | 分类问题 |
| **ARIMA** | 时序专用，只用 y 自己的历史 | 没有像样的解释变量，只有时间序列 |
| **随机森林 / GBDT** | 非线性、自动捕捉交互 | 关系明显非线性、变量多、只要预测不要解释 |

| 竞品 | 关系 | 什么时候换 |
|---|---|---|
| **灰色 GM(1,1)** | 小样本（4–10 个点）时序预测 | 数据极少 |
| **神经网络** | 万能逼近 | 样本量大（上万）、有 GPU 预算 |

---

# 第二层：假设 —— 它成立的前提

## 六大经典假设（高斯-马尔可夫 + 正态）

| # | 假设 | 一句话含义 | 违反了会怎样 | 怎么查 / 怎么救 |
|---|---|---|---|---|
| 1 | **线性** | y 是 x 的线性组合（对**参数**线性即可） | 系统性偏差，残差有形状 | 残差图；加平方项/对数变换 |
| 2 | **误差零均值** | 没有系统性遗漏 | 截距有偏 | 残差均值≈0 |
| 3 | **同方差** | 误差的波动不随 x 变 | 系数仍无偏，但**标准误错 → t 检验失效** | Breusch-Pagan 检验；稳健标准误 / 加权最小二乘 |
| 4 | **无自相关** | 误差之间不相关（**时序数据最易违反**） | 标准误被低估，假显著 | Durbin-Watson；Newey-West 标准误 |
| 5 | **无完全共线** | x 之间不能线性表出 | 系数爆炸、符号反直觉 | **VIF**；删变量 / 岭回归 / PCA |
| 6 | **误差正态** | 用于小样本的 t/F 检验 | 大样本靠中心极限定理自动缓解 | Jarque-Bera、Q-Q 图 |

## 数据条件

| 项 | 要求 | 说明 |
|---|---|---|
| 样本量 | 经验法则 **n ≥ 10k**（k = 变量个数） | n=36、k=4 刚好够；n < k 直接无解 |
| 量纲 | 不要求统一，但**比较重要性必须先标准化** | 否则"系数大"只是单位大 |
| 缺失值 | 不能有 | 删行 / 均值插补 / 多重插补 |
| 异常值 | **敏感**（杠杆点能把整条线拉歪） | 标准化残差 >3、Cook 距离 |
| 外推 | **危险** | x 超出样本范围，预测不可信 |

## 适用边界

- ✅ 关系大致线性、变量不多、需要**说清"为什么"**；
- ❌ 强非线性、强交互、变量几百个、样本上万 → 上树模型；
- ❌ 时序且只有 y 自身历史 → 上 ARIMA；
- ⚠️ **时序数据直接做水平值回归，很容易"伪回归"**（两个都在涨的变量，$R^2$ 天然很高但毫无因果）。

---

# 第三层：原理 —— 它为什么 work

## 3.1 先把字母认全

模型本身只有一行：

$$y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \dots + \beta_k x_{ik} + \varepsilon_i \qquad (i = 1, 2, \dots, n)$$

代入本案例（n = 36，k = 4）：

$$GOLD_i = \beta_0 + \beta_1 \cdot CPI_i + \beta_2 \cdot DXY_i + \beta_3 \cdot REAL_i + \beta_4 \cdot BTC_i + \varepsilon_i$$

**每个字母的含义、维度和本案例的取值**：

| 符号 | 叫什么 | 含义 | 本案例 |
|---|---|---|---|
| $n$ | 样本量 | 多少行数据 | 36 |
| $k$ | 解释变量个数 | 有几列 x（不含常数） | 4 |
| $p$ | 待估参数个数 | $p = k + 1$（含截距） | 5 |
| $y_i$ | 被解释变量 | 第 i 行的真实值 | 金价 |
| $x_{ij}$ | 第 i 行第 j 个 x | 第 i 个月第 j 个指标 | CPI / DXY / REAL / BTC |
| $\beta_j$ | 回归系数 | **要求的东西**，共 p 个 | $\beta_0$…$\beta_4$ |
| $\varepsilon_i$ | 误差项 | 真实世界里的随机扰动，永远看不到 | — |
| $\hat{y}_i$ | 拟合值 | $\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_{i1} + \dots + \hat{\beta}_k x_{ik}$ | 模型算出的金价 |
| $e_i$ | 残差 | $e_i = y_i - \hat{y}_i$（**能算出来**，是 ε 的估计） | 残差 |
| $SSE$ | 残差平方和 | $\Sigma e_i^2$ | 见 3.4 |
| $SST$ | 总平方和 | $\Sigma(y_i - \bar{y})^2$ | 见 3.4 |
| $SSR$ | 回归平方和 | $SST - SSE$ | 见 3.4 |
| $\hat{\sigma}^2$ | 残差方差 | $SSE/(n - k - 1)$ | 见 3.5 |
| $R^2$ / $adjR^2$ | 拟合优度 | 见 3.4 | 0.9292 / 0.9200 |
| $se(\hat{\beta}_j)$ | 系数标准误 | 见 3.5 | 见案例表 |
| $t_j$ | t 统计量 | $\hat{\beta}_j / se(\hat{\beta}_j)$ | 见案例表 |
| $F$ | 整体显著性 | 见 3.6 | 101.66 |
| $VIF_j$ | 方差膨胀因子 | 见 3.7 | 见案例表 |
| $AIC$ / $BIC$ | 信息准则 | 见 3.9 | 326.78 |

> **一句话**：$y = X\beta + \varepsilon$，字母只有四类——**数据（y、X）、待估的（β）、算出来的（ŷ、e）、检验用的（SSE、se、t、F）**。

### 3.2 目标函数：最小二乘在最小化什么

$$SSE(\beta) = \Sigma_i\, e_i^2 = \Sigma_i\, (y_i - \hat{y}_i)^2 = (y - X\beta)^T(y - X\beta)$$

**$\hat{\beta}$ = 让 SSE 最小的那组 β。**

几何直觉：把 y 这个向量**投影**到由 X 的列张成的空间上，投影点就是 ŷ，残差就是那段垂线——所以残差和每个 x 都正交（$X^Te = 0$），这正是"残差与拟合值不相关"的由来。

### 3.3 怎么解出来：正规方程与闭式解

对 $SSE(\beta)$ 关于 β 求导、令导数为 0，得到**正规方程**：

$$X^TX \cdot \hat{\beta} = X^Ty \qquad \rightarrow \qquad \hat{\beta} = (X^TX)^{-1}\, X^Ty$$

**维度**：$X$ 是 $n\times p$，$X^TX$ 是 $p\times p$，$X^Ty$ 是 $p\times 1$，解出的 $\hat{\beta}$ 是 $p\times 1$。

**这几个矩阵怎么来的（手算就靠它俩）**：

$$X = \begin{bmatrix} 1 & x_{11} & x_{12} & \cdots & x_{1k} \\ 1 & x_{21} & x_{22} & \cdots & x_{2k} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & x_{n2} & \cdots & x_{nk} \end{bmatrix} \qquad y = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}$$

- $X^TX$ 的每个元素 = **两列的内积**：第 (j,l) 个元素是 $\Sigma_i\, x_{ij}\cdot x_{il}$（第 1 列全是 1，所以第一行/列就是各列的求和）；
- $X^Ty$ 的每个元素 = **每列与 y 的内积**：第 j 个是 $\Sigma_i\, x_{ij}\cdot y_i$。

所以手算时**只要算出这 8 个和**（$\Sigma x_1$、$\Sigma x_2$、$\Sigma y$、$\Sigma x_1^2$、$\Sigma x_2^2$、$\Sigma x_1x_2$、$\Sigma x_1y$、$\Sigma x_2y$），就能把方程拼出来——完整演示见第四层的「手算演示」。

**k = 1 时退化成一个初中公式**（最简单的一元回归）：

$$\hat{\beta}_1 = \Sigma(x_i - \bar{x})(y_i - \bar{y}) \,/\, \Sigma(x_i - \bar{x})^2$$
$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1\cdot\bar{x}$$

### 3.4 拟合得好不好：SSE / SST / SSR 与 $R^2$

$$SST = \Sigma(y_i - \bar{y})^2 \qquad \text{总平方和（y 自己有多散）}$$
$$SSE = \Sigma(y_i - \hat{y}_i)^2 \qquad \text{残差平方和（模型没解释的部分）}$$
$$SSR = SST - SSE \qquad \text{回归平方和（模型解释掉的部分）}$$

$$R^2 = SSR / SST = 1 - SSE / SST$$
$$adjR^2 = 1 - (1 - R^2)\cdot(n - 1)/(n - k - 1)$$

**为什么要调整 $R^2$**：每加一个变量，SSE 必减 → $R^2$ 必升（哪怕加的是随机噪声）。乘上 $(n-1)/(n-k-1)$ 就是在惩罚"变量多"，所以比模型看 $adjR^2$。

本案例：$R^2 = 0.9292$，$adjR^2 = 1 - (1-0.9292)\times 35/31 = 0.9200$。

## 3.5 系数准不准：标准误与 t 检验

$$\hat{\sigma}^2 = SSE / (n - k - 1)$$ 残差方差的无偏估计（自由度 n−p）

$$Var(\hat{\beta}) = \hat{\sigma}^2 \cdot (X^TX)^{-1}$$ 系数的协方差矩阵

$$se(\hat{\beta}_j) = \sqrt{\hat{\sigma}^2 \cdot [(X^TX)^{-1}]_{jj}}$$ 取对角线的第 j 个元素开根号

$$t_j = \hat{\beta}_j / se(\hat{\beta}_j)$$ 服从 t(n − k − 1)

$$95\%\ 区间 = \hat{\beta}_j \pm t_{0.025,n-k-1} \cdot se(\hat{\beta}_j)$$

**t 值在问什么**：这个系数离 0 有几倍标准误。|t| > 2 大约对应 p < 0.05。

本案例（REAL 这一行）：$t = -114.7359 / 24.0989 = -4.761$，对应 $p < 0.0001$。

## 3.6 整体显著：F 检验

$$F = (SSR / k) / (SSE / (n - k - 1))$$ 服从 F(k, n−k−1)

**直觉**：分子是"平均每个变量解释了多少方差"，分母是"残差方差"。F 大 = 模型解释的远多于没解释的。

本案例：$F = 101.66$，$p = 2.32 \times 10^{-17}$——模型整体高度显著。

## 3.7 共线：VIF 怎么算

把第 j 个 x **当成因变量**，用其余所有 x 去回归它，得到 $R_j^2$，则

$$VIF_j = 1 / (1 - R_j^2)$$

| VIF | 对应 $R_j^2$ | 含义 |
|---|---|---|
| 1 | 0 | 与其他变量毫无关系 |
| 5 | 0.8 | 有 80% 的信息能被别人替代 |
| 10 | 0.9 | 严重共线，系数开始不稳 |

## 3.8 谁更重要：标准化系数

原始系数带单位，不能直接比。把 y 和所有 x 都标准化（减均值除标准差）再回归，得到的系数就是：

$$\beta^*_j = \hat{\beta}_j \cdot s(x_j) / s(y)$$ s() 为样本标准差

本案例：$\beta^*_{REAL} = -114.74 \times 0.41 / 75.08 \approx -0.62$，而 BTC 只有 $+0.16$——**实际利率的重要性是比特币的近 4 倍。**

## 3.9 选模型：AIC / BIC

$$AIC = n \cdot \ln(SSE/n) + 2p$$

$$BIC = n \cdot \ln(SSE/n) + p \cdot \ln(n)$$

拟合越好 SSE 越小、第一项越小；参数越多 p 越大、第二项越大。**越小越好**，且只能在**同一批数据**上比。

### 3.10 预测：点、置信区间、预测区间

给定一组新 $x_0$：

$$\text{点预测} \quad \hat{y}_0 = x_0^T\hat{\beta}$$

$$\text{均值置信区间} \quad \hat{y}_0 \pm t \cdot \sqrt{\hat{\sigma}^2 \cdot x_0^T(X^TX)^{-1}x_0}$$

$$\text{单次预测区间} \quad \hat{y}_0 \pm t \cdot \sqrt{\hat{\sigma}^2 \cdot (1 + x_0^T(X^TX)^{-1}x_0)}$$

差别只在那个 **1**：它代表"这一个具体观测自身的随机波动 ε"，所以预测区间永远比置信区间宽。

### 3.11 可解释性：★★★★★（所有模型里最高）

- 系数直接就是"边际效应"，带单位，能写成一句人话；
- 标准化系数可以横向比"谁更重要"；
- 缺点也在这：**它强行假设"其他条件不变"**，现实里变量是一起动的。

> 线性回归**没有超参数**（岭回归才有 α）——这是它"跑起来最快"的原因，也是它"不够灵活"的原因。

---

## 第四层：操作 —— 怎么跑起来

### 八步流程

① 明确目的（解释 or 预测）
② 数据清洗：缺失值、异常值、量纲
③ 画散点图/相关矩阵，初步看关系
④ 建模：OLS 拟合
⑤ 看整体：$R^2$、调整 $R^2$、F 检验
⑥ 看个体：系数、t、p、VIF（共线）
⑦ 残差诊断：正态 / 同方差 / 自相关 / 线性
⑧ 检验与对比：交叉验证 + 基线模型 + 预测区间

### 手算演示：n = 8 的两变量回归，从原始数据一路算到 t 值

> 36 行不可能手算，但原理必须能手算一遍。下面用 8 个样本把 **3.2–3.7 的每个公式**都代一遍数，结果与 Python 完全一致，你可以逐行核对。

**数据**（$x_1$ = 学习时长，$x_2$ = 上次成绩，y = 本次成绩）：

| i | $x_1$ | $x_2$ | y |
|---|---|---|---|
| 1 | 1 | 60 | 52 |
| 2 | 2 | 55 | 58 |
| 3 | 3 | 70 | 66 |

| i | $x_1$ | $x_2$ | y |
|---|---|---|---|
| 4 | 4 | 65 | 70 |
| 5 | 5 | 80 | 78 |
| 6 | 6 | 75 | 84 |
| 7 | 7 | 90 | 92 |
| 8 | 8 | 85 | 98 |

### 第 1 步：把求和算出来（这是手算的全部工作量）

| 和 | 值 | 和 | 值 |
|---|---|---|---|
| n | 8 | $\Sigma x_1^2$ | 204 |
| $\Sigma x_1$ | 36 | $\Sigma x_2^2$ | 43,100 |
| $\Sigma x_2$ | 580 | $\Sigma x_1 x_2$ | 2,800 |
| $\Sigma y$ | 598 | $\Sigma x_1 y$ | 2,968 |
| $\bar{y} = \Sigma y/n$ | 74.75 | $\Sigma x_2 y$ | 44,630 |
| $\Sigma y^2$ | 46,532 | | |

### 第 2 步：拼出 $X^TX$ 和 $X^Ty$

第一列全是 1，所以 `XᵀX` 的第一行/列就是各列的**求和**：

$$X^TX = \begin{bmatrix} 8 & 36 & 580 \\ 36 & 204 & 2800 \\ 580 & 2800 & 43100 \end{bmatrix} \qquad X^Ty = \begin{bmatrix} 598 \\ 2968 \\ 44630 \end{bmatrix}$$

对照 3.3：`(1,1)=n`、`(1,2)=Σx₁`、`(2,2)=Σx₁²`、`(2,3)=Σx₁x₂`……完全对上。

### 第 3 步：求逆

$$(X^TX)^{-1} = \begin{bmatrix} 14.88125 & 1.13125 & -0.27375 \\ 1.13125 & 0.13125 & -0.02375 \\ -0.27375 & -0.02375 & 0.00525 \end{bmatrix}$$

（手算 3×3 逆矩阵：`A⁻¹ = adj(A)/|A|`；比赛里这一步交给 `np.linalg.inv`，你只要知道它在算什么。）

### 第 4 步：$\hat{\beta} = (X^TX)^{-1}X^Ty$，逐行乘

```
β̂₀ = 14.88125×598 + 1.13125×2968 + (−0.27375)×44630
    = 8898.99 + 3357.55 − 12217.46
    = 39.08

β̂₁ = 1.13125×598 + 0.13125×2968 + (−0.02375)×44630
    = 676.49 + 389.55 − 1059.96
    = 6.08

β̂₂ = (−0.27375)×598 + (−0.02375)×2968 + 0.00525×44630
    = −163.70 − 70.49 + 234.31
    = 0.12
```

**模型**：`本次成绩 = 39.08 + 6.08×学习时长 + 0.115×上次成绩`

读法：多学 1 小时，本次成绩平均高 **6.08 分**；上次成绩高 1 分，本次平均高 **0.115 分**（控制学习时长不变）。

### 第 5 步：拟合值、残差、$R^2$

| i | y | ŷ | e = y − ŷ | e² |
|---|---|---|---|---|
| 1 | 52 | 52.05 | −0.05 | 0.0025 |
| 2 | 58 | 57.55 | +0.45 | 0.2025 |
| 3 | 66 | 65.35 | +0.65 | 0.4225 |
| 4 | 70 | 70.85 | −0.85 | 0.7225 |
| 5 | 78 | 78.65 | −0.65 | 0.4225 |
| 6 | 84 | 84.15 | −0.15 | 0.0225 |
| 7 | 92 | 91.95 | +0.05 | 0.0025 |
| 8 | 98 | 97.45 | +0.55 | 0.3025 |
| **Σ** | | | | **SSE = 2.10** |

```
SST = Σy² − n·ȳ² = 46532 − 8×74.75² = 46532 − 44700.5 = 1831.5
SSR = SST − SSE = 1831.5 − 2.10 = 1829.4

R²    = 1829.4 / 1831.5 = 0.9989
adjR² = 1 − (1 − 0.9989)×(8−1)/(8−3) = 1 − 0.0011×1.4 = 0.9984
```

> 这个例子 `R² = 0.999` 是因为数据是刻意造的（近乎完美线性），**真实赛题一般在 0.6–0.95**，别拿它当预期。

### 第 6 步：$\sigma^2$、标准误、t 值

$$\hat{\sigma}^2 = SSE/(n-k-1) = 2.10/(8-2-1) = 2.10/5 = 0.42$$

$$\hat{\sigma} = \sqrt{0.42} = 0.648$$

$se(\hat{\beta}_j) = \sqrt{\hat{\sigma}^2 \times [(X^TX)^{-1}]_{jj}}$，**只看对角线**：

| 参数 | $\hat{\beta}_j$ | $[(X^TX)^{-1}]_{jj}$ | $\sqrt{0.42\times$对角$}$ | se | t = β/se | p |
|---|---|---|---|---|---|---|
| $\beta_0$ | 39.075 | 14.88125 | $\sqrt{6.250} = 2.500$ | 2.500 | 15.63 | <0.001 |
| $\beta_1$ | 6.075 | 0.13125 | $\sqrt{0.0551} = 0.2348$ | 0.2348 | **25.87** | <0.001 |
| $\beta_2$ | 0.115 | 0.00525 | $\sqrt{0.00221} = 0.0470$ | 0.0470 | 2.449 | **0.058** |

**怎么读 p 值**：$t = 2.449$、自由度 5，查 t 表（双侧）得 p ≈ 0.058 → 在 5% 水平上**边缘显著**（"上次成绩"的作用被"学习时长"部分替代了）。

### 第 7 步：VIF（验证 3.7 的公式）

用 $x_2$ 对 $x_1$ 回归：$R_2^2 = 0.8186$

$$VIF_2 = 1/(1-0.8186) = 5.51$$

同理 $VIF_1 = 5.51$。**VIF > 5 说明两个变量已经高度重叠**——这正是系数 p 值勉强的原因。

### 第 8 步：预测（验证 3.10 的公式）

设 $x_0 = (1, 9, 88)^T$（学 9 小时、上次 88 分）：

$$\hat{y}_0 = 39.075 + 6.075\times9 + 0.115\times88 = 103.87$$

$$s = \sqrt{0.42 \times (1 + x_0^T(X^TX)^{-1}x_0)} = 0.853$$

95% 预测区间 $= 103.87 \pm 2.571\times0.853 = [101.7, 106.1]$

### 与程序结果对照

```
# 同一组数据，statsmodels 输出：
# β = [39.075, 6.075, 0.115]   se = [2.500, 0.235, 0.047]
# t = [15.63, 25.87, 2.449]    R² = 0.9989   adjR² = 0.9984   F = 2177.9
```

手算结果与程序**逐位一致**——这就说明你已经掌握了"字母 → 公式 → 数字"的全过程。

> **比赛里怎么办**：3 个变量以内可以手算核对；4 个以上一律交给 `statsmodels`，但你必须能指着输出表说清每一列是用 3.4–3.7 哪个公式算的。

## 工具

| 工具 | 用途 | 说明 |
|---|---|---|
| **statsmodels** | 要 p 值、t 检验、VIF、置信区间 | **解释型建模首选** |
| **scikit-learn** | 要预测、交叉验证、正则化 | 预测型建模首选 |

| 工具 | 用途 | 说明 |
|---|---|---|
| Excel | 数据分析 → 回归 | 快速看结果，但检验要自己补 |
| MATLAB | `regress` / `fitlm` | A/B 题 |

### 预处理清单

| 处理 | 什么时候做 | 怎么做 |
|---|---|---|
| 标准化 | 要比"谁更重要" | `(x-mean)/std`，系数变"标准化 β" |
| 对数变换 | 变量跨数量级（如比特币 4千→3万）、右偏 | `log(y)`，系数变"弹性" |
| 差分 | 时序、趋势强 | `Δy`，去趋势防伪回归 |
| 虚拟变量 | 分类变量（城市、季节） | 0/1 编码，k 类留一类做基准 |
| 交互项 | 怀疑"效果互相放大" | `x1*x2` |
| 异常值 | 标准化残差>3 或 Cook 距离大 | 核查后删除或稳健回归 |

### 结果怎么检验

| 检验 | 指标 | 通过标准 |
|---|---|---|
| 拟合优度 | $R^2$、调整 $R^2$ | 越高越好（但别只看它） |
| 整体显著 | F 检验 p 值 | $p < 0.05$ |
| 个体显著 | t 检验 p 值 | $p < 0.05$（0.05–0.1 算"边缘显著"） |
| 共线 | VIF | 全部 < 10，最好 < 5 |
| 正态 | Jarque-Bera / Shapiro | $p > 0.05$ |
| 同方差 | Breusch-Pagan | $p > 0.05$ |
| 自相关 | Durbin-Watson | 1.5–2.5 |
| 泛化 | 交叉验证 RMSE | 和训练误差接近 |

---

## 第五层：评价 —— 怎么判断它好不好

### 5.1 误差指标（每个都有公式）

| 指标 | 公式 | 含义 | 本案例（金价） |
|---|---|---|---|
| **RMSE** | $\sqrt{(1/n)\Sigma(y_i - \hat{y}_i)^2}$ | 均方根误差，和 y 同单位 | 21.23 美元 |
| **MAE** | $(1/n)\Sigma\|y_i - \hat{y}_i\|$ | 平均绝对误差，抗异常值 | — |
| **MAPE** | $(1/n)\Sigma\|(y_i - \hat{y}_i)/y_i\|\times 100\%$ | 百分比误差，跨量级可比 | — |
| **$R^2$** | $1 - SSE/SST$ | 解释了多少方差 | 0.9292 |
| **adj$R^2$** | $1 - (1-R^2)(n-1)/(n-k-1)$ | 罚过复杂度 | 0.9200 |

| 指标 | 公式 | 含义 | 本案例（金价） |
|---|---|---|---|
| **LOOCV-RMSE** | 每次留 1 个样本，$n$ 次预测的 RMSE | 泛化误差的近似 | 22.91 |

**为什么还要 LOOCV**：训练集 RMSE 一定比真实泛化误差小（模型"见过"这些点）。留一交叉验证每次拿掉 1 个样本重新拟合，用没见过的那个算误差，才接近"未来预测"的真实水平。

### 5.2 综合判断

| 维度 | 表现 |
|---|---|
| **核心指标** | $R^2$、调整 $R^2$、RMSE、MAE、MAPE、AIC/BIC、交叉验证误差 |
| **基线模型** | ①均值模型（永远预测 $\bar{y}$）②一元回归 ③上一个时间点的值（naive）——**没有基线就没有"好"** |
| **对异常值** | **敏感**（一个杠杆点能改符号），要先查 Cook 距离 |
| **对共线** | 敏感（系数不稳，但预测值往往还行） |
| **过拟合** | 会。变量越多 $R^2$ 越高，但泛化可能更差 |
| **防过拟合** | 调整 $R^2$、交叉验证、AIC/BIC、正则化（岭/Lasso）、变量筛选 |
| **外推** | 最大软肋，超出样本范围基本靠猜 |

**Cook 距离**（判断"哪个点把线拉歪了"）：

$$D_i = e_i^2 / (p \cdot \hat{\sigma}^2) \times [\ h_{ii} / (1 - h_{ii})^2\ ]$$

其中 $h_{ii}$ 是第 i 个样本的杠杆值（hat 矩阵 $H = X(X^TX)^{-1}X^T$ 的对角线）。经验上 $D_i > 1$ 就值得逐个检查；$h_{ii} > 2p/n$ 是高杠杆点。

### 和竞品的对比怎么写

| 对比对象 | 你的论点 |
|---|---|
| vs 一元回归 | 多变量带来多少 $R^2$ 提升、LOOCV 误差降了多少 |
| vs 岭回归 | 共线严重时，岭回归系数更稳、预测误差更小 |
| vs 随机森林 | 线性模型可解释、样本少时更稳；RF 能抓非线性但说不清"为什么" |
| vs ARIMA | 有解释变量用回归，只有时间序列用 ARIMA |

---

## 第六层：比赛 —— 怎么把它写进论文

### 对应题型

| 题型 | 匹配度 | 典型问法 |
|---|---|---|
| A 连续/物理 | ⚠️ 偶尔 | 参数标定、经验公式拟合 |
| B 离散/物理 | ⚠️ 偶尔 | 同样 |
| **C 数据科学** | ⭐⭐ 主战场 | "哪些因素驱动 X""预测未来 Y" |

| 题型 | 匹配度 | 典型问法 |
|---|---|---|
| D 运筹 | ⚠️ 偶尔 | 成本函数估计 |
| **E 环境** | ⭐ 常见 | 污染物浓度与气象因素、碳排放驱动因素 |
| **F 政策** | ⭐ 常见 | 政策效果评估（教育/收入/健康的影响因素） |

## 三个典型场景

1. **C 题•金价/房价/销量驱动因素**：找出显著变量，量化弹性（本文件案例）。
2. **E 题•空气质量**：PM2.5 与温度、湿度、风速、车流量的回归，输出"气象贡献率"。
3. **F 题•政策效果**：教育投入、GDP、城镇化率对某项指标的影响，做政策情景预测。

## 论文呈现顺序

1. 变量选择与数据来源表（y 是什么、x 有哪些、单位、样本区间）
2. 相关性热力图（说明没有严重共线 / 或暴露问题）
3. 模型形式（写出方程，标清 β 的含义）
4. 回归结果表（系数、标准误、t、p、显著性星号、$R^2$、调整 $R^2$、F）
5. 残差诊断图（残差 vs 拟合、Q-Q 图）—— 证明假设成立
6. 重要性排序（标准化系数条形图）
7. 预测 + 置信区间/预测区间
8. 模型对比表（基线 / 全模型 / 正则化）

## 局限性写法（可直接改）

> "多元线性回归假设变量间关系为线性、误差同方差且相互独立。本文数据为月度宏观序列，CPI 与比特币价格均含明显趋势，导致 VIF 偏高（13.9 / 15.1），系数估计的稳定性受限；本文通过岭回归与留一交叉验证验证了预测稳健性，并对残差进行了正态性、异方差与自相关检验。若要进一步消除趋势影响，可改用差分序列或加入时间趋势项。"

## 替代 / 组合

| 组合 | 用途 |
|---|---|
| **回归 + 残差分析** | 本文件已做，标配 |
| **回归 + 岭/Lasso** | 共线、变量多 |
| **回归 + 随机森林** | 线性 vs 非线性的"模型对比"（下一份文件） |
| **回归 + ARIMA** | 回归解释结构，ARIMA 处理残差里的自相关（ARIMAX） |

## 三个常见扣分点

1. **只报 $R^2$，不报调整 $R^2$ 和检验** → 显得不懂；
2. **系数符号和常识相反还不解释** → 一定是共线/遗漏变量，必须查；
3. **拿时序水平值回归就宣称因果** → 伪回归，评委一眼看穿。

---

# 第二部分 • 案例（2022 MCM C 题风格：金价驱动因素）

## 一、题目背景

比特币被称为"数字黄金"，那它到底有没有替代黄金？要回答这个问题，先得搞清楚：**金价到底由什么驱动。**

本题选取 4 个候选驱动因素，用 2019-01 至 2021-12 共 36 个月的月度数据建立多元线性回归，回答三个问题：

1. 哪些因素对金价有**显著**影响？
2. 各因素的影响**有多大**（方向 + 幅度）？
3. 给定未来宏观情景，金价**大概会是多少**（带区间）？

> 数据说明：为教学构造（按现实量级与相关性生成），保证流程可复现；换成 FRED / 世界银行的真实数据后，**流程一行不改。**

### 变量说明

| 符号 | 变量 | 单位 | 预期方向 | 经济逻辑 |
|---|---|---|---|---|
| $y$ | 黄金月均价 | USD/oz | — | 被解释变量 |
| $x_1$ | CPI 指数 | 点 | + | 通胀对冲需求 |
| $x_2$ | 美元指数 DXY | 点 | − | 金价以美元计价，美元强则金价弱 |
| $x_3$ | 实际利率（10Y TIPS） | % | − | 持有黄金的机会成本 |
| $x_4$ | 比特币价格 | USD | +/− | 替代品（负）或风险资产共振（正） |

### 原始数据（36 个月）

| 月份 | CPI | 美元指数 | 实际利率(%) | 比特币(USD) | 金价(USD) |
|---|---|---|---|---|---|
| 2019-01 | 251.7 | 95.70 | 0.684 | 5,504 | 1,393 |
| 2019-02 | 252.5 | 93.66 | 0.231 | 4,189 | 1,438 |
| 2019-03 | 253.3 | 94.46 | 0.169 | 5,940 | 1,465 |
| 2019-04 | 254.0 | 96.45 | 1.005 | 5,431 | 1,362 |
| 2019-05 | 254.9 | 95.83 | 0.222 | 4,941 | 1,433 |
| 2019-06 | 255.2 | 94.70 | 0.203 | 4,505 | 1,473 |
| 2019-07 | 256.3 | 95.74 | 0.384 | 5,701 | 1,401 |
| 2019-08 | 257.6 | 95.80 | 0.497 | 6,709 | 1,423 |
| 2019-09 | 258.3 | 91.99 | -0.420 | 4,962 | 1,605 |
| 2019-10 | 258.6 | 91.44 | -0.827 | 6,140 | 1,637 |
| 2019-11 | 260.0 | 92.90 | -0.389 | 4,944 | 1,563 |
| 2019-12 | 260.2 | 94.60 | 0.274 | 6,557 | 1,480 |

| 月份 | CPI | 美元指数 | 实际利率(%) | 比特币(USD) | 金价(USD) |
|---|---|---|---|---|---|
| 2020-01 | 261.6 | 92.42 | -0.433 | 7,083 | 1,566 |
| 2020-02 | 261.6 | 93.00 | -0.189 | 6,882 | 1,564 |
| 2020-03 | 262.1 | 95.73 | 0.528 | 8,954 | 1,444 |
| 2020-04 | 263.9 | 94.65 | -0.005 | 9,552 | 1,536 |
| 2020-05 | 263.9 | 93.17 | -0.295 | 9,072 | 1,583 |
| 2020-06 | 264.4 | 92.63 | -0.353 | 8,839 | 1,537 |
| 2020-07 | 265.6 | 92.60 | -0.428 | 14,324 | 1,623 |
| 2020-08 | 267.7 | 94.11 | 0.081 | 13,452 | 1,542 |
| 2020-09 | 267.5 | 94.06 | -0.261 | 14,559 | 1,567 |
| 2020-10 | 268.6 | 93.11 | -0.379 | 17,363 | 1,613 |
| 2020-11 | 269.0 | 93.11 | -0.413 | 18,959 | 1,603 |
| 2020-12 | 269.6 | 95.01 | -0.073 | 18,192 | 1,571 |
| 2021-01 | 270.1 | 94.98 | -0.366 | 21,684 | 1,599 |
| 2021-02 | 271.8 | 94.16 | -0.198 | 20,153 | 1,560 |
| 2021-03 | 271.8 | 93.35 | -0.259 | 24,351 | 1,646 |
| 2021-04 | 272.6 | 95.14 | 0.253 | 28,325 | 1,508 |
| 2021-05 | 272.9 | 96.30 | 0.216 | 24,643 | 1,570 |
| 2021-06 | 274.3 | 97.67 | 0.635 | 25,679 | 1,507 |
| 2021-07 | 275.2 | 97.10 | 0.601 | 26,760 | 1,477 |
| 2021-08 | 276.0 | 96.53 | 0.299 | 33,073 | 1,547 |
| 2021-09 | 276.8 | 97.01 | 0.349 | 31,115 | 1,522 |
| 2021-10 | 277.6 | 96.40 | 0.074 | 34,241 | 1,567 |
| 2021-11 | 277.9 | 96.82 | 0.207 | 33,950 | 1,543 |
| 2021-12 | 278.8 | 95.35 | -0.249 | 33,431 | 1,644 |

## 二、完整建模流程（8 步）

### 第 1 步：描述统计

| 变量 | 均值 | 标准差 | 最小 | 最大 |
|---|---|---|---|---|
| CPI | 265.39 | 8.20 | 251.70 | 278.80 |
| DXY | 94.66 | 1.62 | 91.44 | 97.67 |
| REAL | 0.04 | 0.41 | -0.83 | 1.00 |

| 变量 | 均值 | 标准差 | 最小 | 最大 |
|---|---|---|---|---|
| BTC | 15,282 | 10,331 | 4,189 | 34,241 |
| GOLD | 1,530.89 | 75.08 | 1,362 | 1,646 |

**注意量纲**：BTC 的标准差是 10331，GOLD 只有 75——如果直接比系数大小，会得出"比特币最重要"的荒谬结论。**必须标准化后再比**（第 5 步）。

## 第 2 步：相关性初筛

| | CPI | DXY | REAL | BTC | GOLD |
|---|---|---|---|---|---|
| **CPI** | 1.000 | 0.352 | -0.109 | **0.949** | 0.550 |
| **DXY** | 0.352 | 1.000 | **0.827** | 0.506 | -0.514 |
| **REAL** | -0.109 | 0.827 | 1.000 | 0.061 | **-0.843** |
| **BTC** | 0.949 | 0.506 | 0.061 | 1.000 | 0.397 |
| **GOLD** | 0.550 | -0.514 | -0.843 | 0.397 | 1.000 |

**两个警报已经响了**：

1. `CPI ↔ BTC` 相关 **0.949**，`DXY ↔ REAL` 相关 **0.827** → 共线预警；
2. `BTC ↔ GOLD` 只有 0.397，看起来很弱——**但别急着删**，两两相关看不到"控制其他变量后"的效应。

## 第 3 步：建立模型

$$GOLD = \beta_0 + \beta_1 \cdot CPI + \beta_2 \cdot DXY + \beta_3 \cdot REAL + \beta_4 \cdot BTC + \varepsilon$$

## 第 4 步：OLS 估计结果

**$R^2 = 0.9292$，调整 $R^2 = 0.9200$，$F = 101.66$（$p = 2.32 \times 10^{-17}$），AIC = 326.78**

| 变量 | 系数 | 标准误 | t 值 | p 值 | 显著性 |
|---|---|---|---|---|---|
| 常数项 | 1509.27 | 730.45 | 2.066 | 0.0473 | ** |
| **CPI** | **+3.7442** | 1.6332 | 2.293 | 0.0288 | ** |
| DXY | −10.4118 | 6.7268 | −1.548 | 0.1318 | |
| **REAL** | **−114.7359** | 24.0989 | −4.761 | 0.0000 | *** |
| BTC | +0.0012 | 0.0013 | 0.868 | 0.3920 | |

**怎么读**：

- **实际利率**：控制其他变量不变，实际利率每升 1 个百分点，金价平均跌 **114.7 美元/盎司**（p<0.001，高度显著）——完全符合"机会成本"理论；
- **CPI**：每升 1 点，金价平均涨 **3.74 美元**（p=0.029，显著）——通胀对冲成立；
- **美元指数**：方向对（负），但 **p=0.132 不显著**——被实际利率"抢走"了解释力（两者相关 0.827）；
- **比特币**：p=0.392，**不显著**——控制宏观因素后，比特币对金价没有独立影响。这其实是对"数字黄金替代论"的一个有意思的反证。

> **这张表每一列是怎么算出来的**（对回第三层的公式，别当黑箱）：
>
> | 表里的列 | 来自哪个公式 |
> |---|---|
> | 系数 | 3.3 的 $\hat{\beta} = (X^TX)^{-1}X^Ty$ |
> | 标准误 | 3.5 的 $\sqrt{(\hat{\sigma}^2 \cdot [(X^TX)^{-1}]_{jj})}$ |
> | t 值 | 3.5 的 $\hat{\beta}_j / se(\hat{\beta}_j)$ |
> | p 值 | t 分布双侧面积，自由度 $n-k-1 = 31$ |
> | $R^2$ / 调整 $R^2$ | 3.4 |
> | F | 3.6 |
> | AIC | 3.9 |
>
> 想看完整的算术过程（含矩阵求逆、逐行相乘），翻到第四层的 **「手算演示」**——8 个样本从头算到尾。

## 第 5 步：共线性诊断（VIF）

| 变量 | VIF | 判断 |
|---|---|---|
| CPI | **13.913** | 严重（>10） |
| DXY | 9.239 | 警惕（接近 10） |
| REAL | 7.481 | 警惕 |
| BTC | **15.088** | 严重（>10） |

**为什么会这样**：CPI 和 BTC 都是**单调上升的趋势变量**，两者互相能解释 95%；DXY 和 REAL 是经济学上的"孪生变量"。

**后果**：系数估计不稳（换一段样本，符号可能翻转），但对**预测值**影响不大。
**处理**：①删掉冗余变量；②岭回归；③对趋势变量取差分/对数收益率；④主成分回归。

> 这是本案例**故意保留**的真实毛病——宏观时序数据几乎必然共线。论文里把它写出来 + 给出处理方案，比假装 VIF=1 更得分。

## 第 6 步：残差诊断

| 检验 | 统计量 | 结论 |
|---|---|---|
| 正态性（Jarque-Bera） | p = 0.7258 | 不拒绝正态 ✅ |
| 正态性（Shapiro-Wilk） | p = 0.5420 | 不拒绝正态 ✅ |
| 同方差（Breusch-Pagan） | p = 0.5247 | 不拒绝同方差 ✅ |
| 自相关（Durbin-Watson） | 2.766 | 略偏大（>2.5），提示轻微负自相关 ⚠️ |
| 线性（残差 vs 拟合相关） | −0.0000 | 无系统偏差 ✅ |

**结论**：三大假设基本满足，模型可用；DW 略大，若严格可改用 Newey-West 稳健标准误。

### 第 7 步：标准化系数（谁更重要）

| 变量 | 原始系数 | 标准化系数 | 重要性排名 |
|---|---|---|---|
| **REAL** | −114.7359 | **−0.6225** | **1** |
| CPI | 3.7442 | +0.4088 | 2 |
| DXY | −10.4118 | −0.2249 | 3 |
| BTC | 0.0012 | +0.1612 | 4 |

> 看图就明白：原始系数里 BTC 是 0.0012、REAL 是 −114.7，差 10 万倍，**根本没法比**；标准化后 REAL 是 BTC 的近 4 倍。**"系数绝对值大"≠"重要"，这是初学者最常犯的错。**

### 第 8 步：情景预测

**情景**：CPI = 285、DXY = 98、实际利率 = 1.5%、BTC = 40000（大致对应"通胀继续、美元走强、加息"的组合）

| 项目 | 数值 |
|---|---|
| 点预测 | **1430.8 美元/盎司** |
| 95% 置信区间（均值的区间） | [1373.8, 1487.8] |
| 95% 预测区间（单次观测） | [1359.2, 1502.3] |

**必须分清这两个区间**（论文里写错会被扣分）：

- **置信区间**回答"如果这种宏观环境重复很多次，**平均**金价在哪"；
- **预测区间**回答"**下个月**的真实金价会在哪"，因为多了 ε 的随机性，所以更宽。

---

## 三、模型对比（论文加分项）

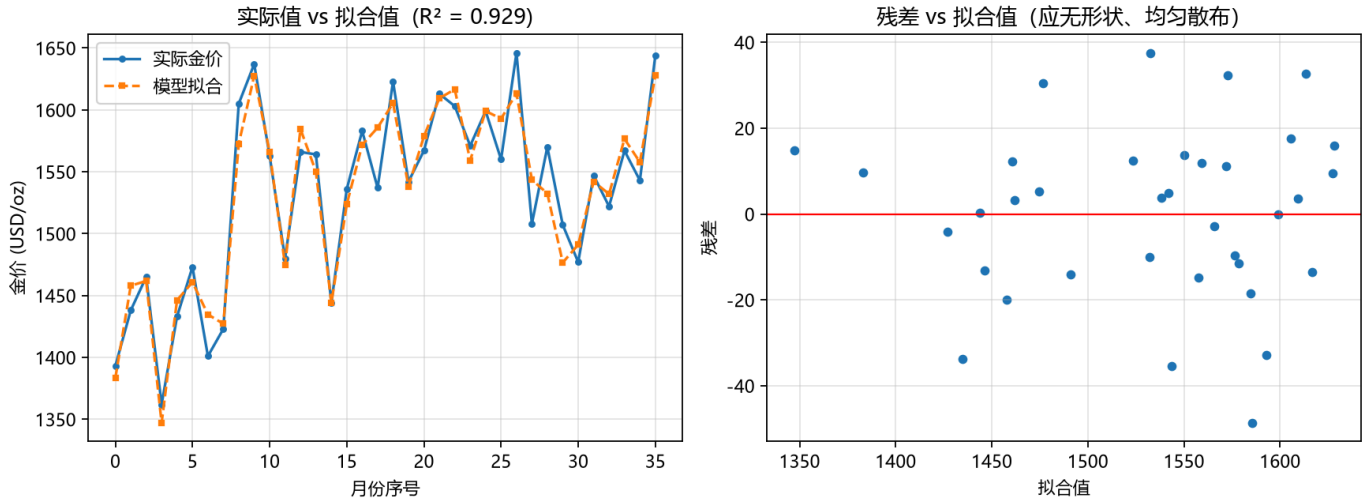
| 模型 | $R^2$ | 调整 $R^2$ | AIC | LOOCV-RMSE |
|---|---|---|---|---|
| 基线：仅 CPI | 0.3027 | 0.2821 | 403.11 | 65.54 |
| **全模型：4 个变量** | **0.9292** | **0.9200** | **326.78** | **22.91** |
| 岭回归（α=1，标准化） | 0.9287 | — | — | — |

**三个结论**：

1. 从"仅 CPI"到"四变量"，调整 $R^2$ 从 0.28 跳到 0.92，**LOOCV-RMSE 从 65.5 降到 22.9**——多出来的变量带来的是真泛化收益，不是过拟合；
2. 岭回归的 $R^2$（0.9287）只比 OLS 低 0.0005，但**系数更稳**——这就是共线时用正则化的理由；
3. 残差标准差 21.23 美元，相对金价 1530 约 **1.4%**，预测精度可以接受。

---

## 四、结果图




**左图**：拟合曲线基本咬住实际值，$R^2$=0.929。
**右图**：残差均匀散在 0 附近，但**中段偏负、两头偏正**，呈轻微 U 形——提示可能存在遗漏的非线性（如金价对实际利率的反应不对称）。改进方向：加 `REAL²` 项或改对数模型。

---

## 五、完整 Python 代码

见同目录 `mlr_demo.py`（约 210 行）。核心只有五行：

```
import statsmodels.api as sm
Xc = sm.add_constant(X)           # 加截距
model = sm.OLS(y, Xc).fit()       # 最小二乘
model.params                      # 系数
model.pvalues                     # p 值
model.rsquared_adj                # 调整 R²
```

配套检验：

```
from statsmodels.stats.outliers_influence import variance_inflation_factor  # VIF
sm.stats.diagnostic.het_breuschpagan(resid, Xc)   # 异方差
sm.stats.stattools.durbin_watson(resid)           # 自相关
from scipy import stats
stats.jarque_bera(resid)                          # 正态性
```

---

## 六、运行方法与结果

```
cd /d/大学/美赛
python -X utf8 mlr_demo.py
```

**实际输出（节选）**：

```
② 回归结果
  R² = 0.9292   调整 R² = 0.9200   F = 101.66 (p = 2.32e-17)

  变量                  系数        标准误       t 值       p 值    显著性
  const       1509.2686  730.4537    2.066    0.0473   **
  CPI            3.7442    1.6332    2.293    0.0288   **
  DXY          -10.4118    6.7268   -1.548    0.1318
  REAL        -114.7359   24.0989   -4.761    0.0000   ***
  BTC            0.0012    0.0013    0.868    0.3920

⑦ 模型对比
  模型                              R²       调整R²        AIC  LOOCV-RMSE
  基线：仅 CPI                   0.3027    0.2821    403.11       65.54
  全模型：4 个变量                 0.9292    0.9200    326.78       22.91
  岭回归(α=1，标准化)              0.9287         -         -           -
```

---

# 第三部分 · 速记与自测

## 一页速记

| 问题 | 答案 |
|---|---|
| 它做什么? | 解释"谁影响 y、影响多大" + 预测 y |
| 核心方法? | 最小二乘：让残差平方和最小 |
| 最关键假设? | 线性、同方差、无自相关、无共线、误差正态 |
| 必查什么? | VIF（共线）、残差三检验、调整 $R^2$ |
| 最容易错? | 拿原始系数比重要性（要标准化）、拿水平值做时序回归（伪回归） |
| 论文必写? | 变量表 + 回归结果表 + 残差图 + 模型对比 |

## 自测三问

1. $R^2$ = 0.95 但 VIF 全是 20，这个模型能用吗？为什么？
2. 系数符号和经济学常识相反，最先怀疑什么？
3. n = 12、变量 5 个，能直接做多元回归吗？

**参考答案**

1. **预测勉强能用，解释不能用。**共线不破坏预测精度，但会让系数方差爆炸、符号不稳，此时 t 检验几乎全部失效。应删变量、用岭回归或做差分。
2. 先查**共线**（VIF）和**遗漏变量**，再看样本区间是否太短、异常值是否在撬动结果。符号翻转是共线的典型症状。

3. 不能。经验法则 n ≥ 10k，即至少 50 个样本；12 个样本配 5 个变量，$R^2$ 会虚高到接近 1，纯属过拟合。应减变量或改用岭回归/主成分。

---

## 与其他模型的衔接

| 下一步 | 说明 |
| --- | --- |
| 随机森林回归 | 抓非线性、看特征重要性，与本模型做"线性 vs 非线性"对比 |
| ARIMA | 处理本模型残差里的自相关（ARIMAX） |
| 岭/Lasso | 解决本案例的 VIF 问题 |